Kann Malware in Android-Apps automatisch gefunden werden?

Cöllen, Markus

Hochschule Mannheim

Fakultät für Informatik

Paul-Wittsack-Str. 10, 68163 Mannheim

Zusammenfassung—An dieser Stelle steht eine kurze Zusammenfassung des Inhaltes des Dokuments.

Inhaltsverzeichnis

1	Einleitu	ng	1
2	Grundla	ngen	1
	2.1	Was ist Android?	1
	2.2	Android Update Problematik	2
	2.3	Application Sandbox	2
	2.4	Permission Model	2
	2.5	Sicherheit des Google Play Store	2
	2.6	Malware	3
	2.7	Dynamische Analyse	2 3 3 3 3
	2.8	Statische Analyse	3
		2.8.1 Kontrollflussanalyse	3
		2.8.2 Datenflussanalyse	4
	2.9	Gegenüberstellung von statischer	
		und dynamischer Analyse	4
3	Erkennı	ıngsmechanismen	4
	3.1	signaturbasierte Malwareerkennung.	4
	3.2	Virenschutz durch Machine Learning	4
		3.2.1 Data Flow	4
		3.2.2 Control Flow	4
		3.2.3 Taint Analysis	4
4	Bouncer	•	4
5	Fazit		4
Abkürzungen			
Abkurzungen			4
Abbildungen			
Literatur			

1. Einleitung

Smartphones bieten aufgrund ihrer vielen Schittstellen zur Außenwelt, wie z.B. WLAN, Bluetooth, NFC, USB usw. viele Angriffspunkte. Ein Hauptgrund, warum Smartphones mit dem Android Betriebssystem so beliebt für Angreifer sind, ist der hohe Verbreitungsgrad dieser Geräte. Dieser liegt im Jahr 2018 bei ca. 86 Prozent und ist somit Sechs mal so hoch wie der Konkurrent IOS mit knapp 16 Prozent Marktanteil [11]. Da Malware-Autoren immer mehr auf Verschleierungsmechanismen

wie Komprimierung, Verschlüsselung oder sich selbst modifizierender Programmcode setzten, wird es für Antiviren Herstellern zunehmend schwieriger diese als schädliche Software zu erkennen [10].

2. Grundlagen

2.1. Was ist Android?

Das Betriebssystem Android ist eine umfassende Open Source Plattform für Smartphones. Eigentümer des Android Betriebssystem ist die Open Handset Alliance, welches ein Konsortium von 84 Unternehmen ist, Ihr Ziel ist es ëine beschleunigte Innovation im Mobilbereich, um dem Benutzer ein reicheres, kostengünstigeres und besseres Mobilerlebnis zu bieten"[8]. Die Android Architektur besteht aus insgesamt fünf Schichten, dem Linux Kernel, Bibliotheken, Android-Laufzeitumgebung, Application-Frameworks und auf der obersten Schicht die Anwendungen.




Abbildung 1. Android Architektur [8]

Weil Android unter der Apache Open-Source Lizenz freigegeben ist und das Betriebssystem auf dem Linux-Kernel basiert, können Hersteller das Android Betriebssystem beliebig verwenden und für ihre Produkte anpassen. Zudem dient der Linux-Kernel als eine Abstraktion zwischen Software und Hardware und somit kann Android

auf verschiedenen Geräten eingesetzt werden. Aufgrund der Tatsache, dass Linux über ein etabliertes Sicherheitskonzept verfügt [15], greift Android auf viele Schutzmechanismen des Linux Kernels zurück oder benutzt diese als ihre Basis[14]. Zudem verwendet Android viele von Linux mitgebrachten Funktionen wie z.B. die Unterstüzung für Speicherverwaltung, Power-Management und Netzwerkzugriff. Wie man in Abbildung 1 sehen kann, gibt es zudem noch viele von Android mitgebrachte Bibliotheken wie SQLite (eine SQL Datenbank) oder OpenGL (eine 3-D-Grafikbibliothek). Bis zu den Android Versionen 4.x war die Dalvik VM ein Hauptbestandteil des Android Betriebssystem. Hierdurch wurde die geschriebenen Apps erst in Bytecode formatiert wenn sie auch wirklich gebraucht werden. Ab Android 5.x wurde dies durch den Ahead-of-time-Compiler ersetzt. Dieser übersetzt die Apps schon beim installieren in Bytecode-Format. Hierdurch wird sich bessere Performance und eine Beschleunigung von Apps erhofft ohne dabei Flexibilität verzichten zu müssen[3]. Die Schicht Application-Framework stellt einem Entwickler die unterschiedlichsten Dienste zur Verfügung. Hierzu zählen viele Dienste, welche für eine Applikation die Infrastruktur zur Verfügung stellt, wie die Positionsermittlung, Sensoren, WLAN oder Telefoniefunktionen. Diese Schicht ist für die Programmierung von Android Apps die wichtigste und daher auch am gründlichsten Dokumentiert. Die oberste Schichte sind die Anwendungen. Diese sind teilweise schon vorinstalliert oder können heruntergeladen und installiert werden.

2.2. Android Update Problematik

Wie man in Abbildung 2 sehen kann verdrängen die neueren Android Versionen die älteren. Allerdings ist Android Oreo, mit gerade mal 4,6 Prozent, eine der am wenigsten vertretenen Version, obwohl sie die neueste und auch schon seit dem 27. August 2017 auf dem Markt ist.




Abbildung 2. Verteilung der Android-Versionen im Jahr 2018 [1]

Dies liegt daran, dass nicht jede Android Version mit jedem Handy kompatibel ist. Die Smartphone Hersteller müssen die Versionen an ihre Geräte und die jeweilige Hardware anpassen. Diese umfassen Anpassungen an WLAN, Kamera, Bluetooth, GPS usw. Anschließend müssen die erstellten Anpassungen noch umfangreich getestet werden, was auch noch viel Zeit in Anspruch nimmt. Weil die Hersteller oft neue Produkte verkaufen wollen

und das Updaten älterer Smartphones zu teuer und zeitaufwendig ist, bleibt den Nutzern oft nichts anderes übrig, als neue Smartphones zu kaufen. Andernfalls behält man ein Smartphone mit einer veralteten Version und bekannten Sicherheitslücken. [14].

2.3. Application Sandbox

Linux arbeitet als ein Mehrbenutzer-Betriebssystem. Dies bedeutet, dass es mehrere Nutzer geben kann und das Betriebssystem verhindert, dass Daten eines Nutzers von einem anderen Nutzer eingesehen, geändert oder gelöscht werden können. Diese Nutzermanagement wird beim Application Sandboxing verwendet. Hierbei erhält jede Applikation eine eigene Nutzer-ID und führt diese in einem separaten Prozess aus. Somit gewährleistet Android, dass eine Applikation anderen Applikationen oder dem Betriebssystem keinen Schaden zufügen kann. Sollte eine Applikation aber durch das Ausnutzen einer Schwachstelle oder einer Sicherheitslücke an Root-Rechte kommen, kann die Applikation dieses Application Sandboxing einfach umgehen. Wie schon in Abschnitt 2.2 beschrieben, gibt es wegen den stark verzögerten Android Updates oft Sicherheitslücken, welche über längere Zeit bekannt sind und leicht ausgenutzt werden können um Root-Rechte zu erlangen [8].

2.4. Permission Model

Standardmäßig hat eine Applikation keinen Zugriff auf Daten außerhalb der Sandbox. Sollte eine Applikation Systemressourcen außerhalb dieser verwenden wollen, muss erst eine Zugriffsanfrage gestellt werden. Geschützte Ressourcen sind z.B. Kamera, SMS, Bluetooth usw. [12]. Diese Rechte können bei einer Anfrage allerdings nur angenommen oder abgelehnt werden, bestimmte Einschränkungen können also nicht vorgenommen werden. Hier sollte der Nutzer sich Gedanken darüber machen, welche Applikationen welche Systemressourcen wirklich benötigen. Sollte ein Spiel wie z.B. Snake Rechte anfordern SMS zu verschicken, könnte dem Nutzer klar werden, dass etwas mit der Applikation nicht stimmt.

2.5. Sicherheit des Google Play Store

Anders als bei IOS, bei welchem die Nutzer an den Apple Store gebunden sind, können die Android Benutzer selbst entscheiden welchen Store sie verwenden. Der Google Play Store ist mit 82 Milliarden Downloads [2] mit Abstand die größte Plattform. Er wurde am 28. August 2008 unter dem Namen Android Market veröffentlicht. Dieser bietet den Nutzern einfaches herunterladen und installieren von mobilen Anwendungen, sogenannten Applikationen. Im Google Play Store sind inzwischen über 3,7 Millionen Anwendungen bereit zum Herunterladen [9] und jeden Monat kommen ca. 30.000 neue Applikationen hinzu [4]. Durch den rasanten Wachstum steigt auch die Anzahl von schädlicher Software, sogenannter Malware. Der Anteil von bösartigen Applikationen ist von 2011 bis 2013 um 388% gewachsen [13]. Da nicht alle Anwendungen von Mitarbeitern geprüft werden können, hat Google das Programm Bouncer ins Leben gerufen (siehe Kapitel 4). Android bietet zudem die Möglichkeit per Remote-Verbindung Applikationen zu installieren und zu löschen. Hierfür braucht man lediglich Zugriff auf den Google Play Account. Falls ein Angreifer an diese Daten kommen sollte, könnte er ohne Erlaubnis des Nutzers, Applikationen aus dem Google Play Store auf dem Smartphone installieren.

2.6. Malware

Bei dem Begriff Malware handelt es sich um ein Kunstwort, welches sich aus malicous und software zusammensetzt und bezeichnet Programme, welche unerwünschte oder auch schädliche Funktionen ausführen. Maleware kann man prinzipiell in drei unterschiedliche Hauptkathegorien unterteillen, Viren, Würmer und Trojaner. Ein Virus ist eine Software, welche sich selbst vervielfälltigen kann. Durch das Ausführen einer Infizierten Anwendung wird das Programm gestartet und schleust sich in anderen Programmen oder Dokumenten ein. Die sogenannten Würmer haben ähnliche Eigenschaften wie Vieren, der Hauptunterschied liegt darin, dass sie sich über das Intra- order Internet vermehren können und oft keine Interaktion mit den betroffenen Benutzern benötigen. Die dritte und gefährlichste Kathegorie ist das sogenannte Trojanische Pferd. Dieses täuscht dem Nutzer ein nützliches Programm vor, führt allerdings ohne Wissen des Benutzers im Hintergrund schädliche Funktionen und Routinen durch. Allerdings enthält die meiste Malware mehr als nur eine schädliche Funktion, was eine eindeutige Klassifikation fast unmöglich macht. Weitere Arten sind zudem Spyware, Exploits, Backdoors und Rootkits. Jede dieser Arten kann von ihren Maleware-Authoren druch Verschleierungsmechanismen wie Komprimierung, Verschlüsselung oder sich selbst modifizierender Programmcode verschleiert werden, was das Auffinden durch Vierenprogramme um einiges erschwert. [10] Malware stellt desshalb eine immer größer werdende Bedrohung dar und durch den rasanten Wachstum ist eine manuelle Auswertung mittlerweile unmöglich geworden. Obwohl es sich bei vielen neuen Arten um verschiedene Varianten bereits bekannter Malware handelt, müssen Analysten erst jedes Sample erneut analysieren um dies feststellen zu können [16]. Bei der Analyse kann grundsätzlich in zwei Arten unterschieden werden: Statische und Dynamische Analyse (siehe Kapitel 2.8 und 2.7).

2.7. Dynamische Analyse

Bei der dynamischen Analyse wird das Programm während der Laufzeit untersucht. Der Ablauf besteht dabei aus drei Teilen: der Ausführung des Programms, der Protokollierung des Ablaufes und der Ergebnisse und das Analysieren dieser [6]. Ein Beispiel der dynamischen Analysemethoden ist das Testen. Ein bedeutender Nachteil ist es, dass nicht immer alle Eingabeparameter überprüft werden können da diese exponentiell mit der Anzahl der Parameter steigt. Daher werden oft nur Randund Grenzfälle geprüft. Weitere Probleme können bei der Netzkommunikation, der Erstellung von Zufallszahlen wie auch bei Nutzereingaben auftreten. Wegen all dieser Eigenschaften eines Programmes ist eine Reproduzierbarkeit der Ergebnisse nicht gegeben. Zudem gibt es die

Möglichkeit für Malware während Laufzeit zu erkennen, ob sie überprüft wird und kann sich gegebenenfalls zu diesem Zeitpunkt harmlos verhalten. Viele dieser Nachteile lassen sich durch eine statische Analyse vermeiden welche im Abschnitt 2.8 vorgestellt wird.

2.8. Statische Analyse

Bei der statischen Analyse wird versucht durch reverse engineering Code aus der Maleware zu extrahieren um somit auf das Verhalten des Programmes schließen zu können. Dieser extrahierte Code kann anschließend eingehend untersucht werden. [16]. Diese Analysemethode wird also im Gegensatz zu dynamischen Analyse nicht zur Laufzeit des Programms angewandt und somit muss die App auch nicht ausgeführt werden. Da die korrekte Abbildung der Struktur des Quellcodes eine komplexe Aufgabe ist, wird hierzu oft ein Compiler verwendet. Dieser erzeugt aus dem Quellcode mit der Hilfe eines Lexers einen Tokenstream, also eine Folge aus den kleinsten sinntragenden Einheiten des Programms wie Literalen, Bezeichnern und Schlüsselwörtern, ein Beispiel hierfür wäre eine if-else Anweisung. Anschließend erzeugt ein Parser aus dem Tokenstream einen abstrakten Syntaxbaum, welcher die syntaktischen Zusammenhänge der einzelnen Tokens darstellt. Durch eine anschließende semantische Analyse wird aus dem Syntaxbaum ein Graph, auf welchen beispielsweise eine Kontrollflussanalyse2.8.1 oder Datenflussanalyse 2.8.2 durchgeführt werden kann.

2.8.1. Kontrollflussanalyse. Bei der Kontrollflussanalyse wird untersucht, welcher Block im zu untersuchendem Programm die Kontrolle an welchen Block übergibt, und welche Funktionen dabei erreichbar sind. Zudem wird überprüft welche Werte Parameter einer Funktion möglicherweise zugewiesen bekommen. Um die Ergebnisse zu Analysieren wird ein Kontrollflussgraph erstellt. Dieser besteht aus einer Menge Knoten welche die Grundblöcke des Programmes darstellen. Zudem gibt es noch eine Menge von gerichteten Kanten, welche einen Übergang von einem Block zu einem anderen darstellen. Diese zeigen wie die Kontrolle von einem Block zu einem anderen übergeht. [17] Die Abbildung 3 zeigt ein Beispiel eines solchen Kontrollflussgraphen.




Abbildung 3. Kontrollflussgraph [5]

Wie man in Abbildung 3 sehen kann, wird für jede Anweisung ein Block erstellt. int ergebnis=0; ist die erste Anweisung und somit auch Block 1. Block 2 ist die if Bedingung und je nachdem ob sie erfüllt wird geht sie zu Block 3, ergebnis=30; oder zur nächsten if Bedingung über. Bei dieser wird entweder der if Block oder der else Block ausgeführt, daher kommt auch die Verzweigung bei Block 4. return ergebnis; wird immer ausgeführt, daher laufen Block 5 und Block 6 auch in Block 7 wieder zusammen. Diese Kontrollflussgraphen werden auch zum überprüfen der Überdeckung verwendet.

2.8.2. Datenflussanalyse. Bei der Datenflussanalyse wird untersucht, welche Teiles des Programmes welche Daten weitergeben und welche Abhängigkeiten daraus resultieren. Als Grundlage dieser Methode wird ein Kontrollflussgraph aus Kapitel 2.8.1 verwendet. Die Datenflussanalyse untersucht, wie sich Daten durch die einzelnen Blöcke verändern. Enthält ein Block beispielsweise den Code x=1, so verändert sich der Wert von x nach dem Block auf 1. Diese gesamten Änderungen jedes Blocks werden überwacht und aufgezeichnet. [17]

2.9. Gegenüberstellung von statischer und dynamischer Analyse

Durch eine dynamische Analyse können durch die Ausführung des Programmes konkrete Fehler gefunden werden, allerdings kann durch diese Methode nicht die Fehlerfreiheit des Programmes bewiesen werden, da das Programm meistens nicht mit allen Parametern gestartet und durchgeführt werden kann. Bei der statischen Analyse kann das Ausführen des Programmes mit allen möglichen Parametern betrachtet werden. Somit kann bewiesen werden, dass bestimmte Fehlerarten nicht auftreten können. Allerdings können Fehler auftreten welche durch das Fehlen entfernter Zusammenhänge entstehen. Beide Analysemethoden haben Vor- und Nachteile, ergänzen sich allerdings gegenseitig gut, daher sollten beide Methoden zusammen verwendet werden. [7]

3. Erkennungsmechanismen

3.1. signaturbasierte Malwareerkennung

Die am meisten Vertretene Methode der Malware-erkennung ist die auf Signatur basierte Erkennung von Malware. Diese Methode basiert auf der statischen Analyse 2.8 und extrahiert aus einem potentiellen Malware-Programm eine eindeutige Byte-Folge , welche als eindeutige Identifikation und Signatur dient, und vergleicht diese mit allen verfügbaren Signaturen in der Erkennungssoftware Datenbank. Wird diese Signatur in einem anderen Programm gefunden, kann mit einer hohen Sicherheit davon ausgegangen werden, dass das Programm schädliche Komponenten enthält. Der erste große Nachteil dabei ist, dass nur bereits bekannte Malwarearten gefunden werden können, zudem ist das Gerät in der gesamten Zeit in der die Signaturen verglichen werden gegen Angriffe ungeschützt. [10]

3.2. Virenschutz durch Machine Learning

Glaubt man den Firmen , welche Machine Learning für ihr Virenerkennung einsetzten, so hat die traditionelle Malwareerkennung ein Ende gefunden. Mithilfe von

- **3.2.1.** Data Flow.
- 3.2.2. Control Flow.
- 3.2.3. Taint Analysis.
- 4. Bouncer
- 5. Fazit

Abkürzungen

Abbildungsverzeichnis

1	Android Architektur [8]			
2				
	2018 [1]	2		
3	Kontrollflussgraph [5]			

Literatur

- [1] Anteile der verschiedenen Android-Versionen an allen Geräten mit Android OS weltweit im Zeitraum 10. bis 16. April 2018. https://de.statista.com/statistik/daten/studie/180113/umfrage/anteil-derverschiedenen android versionen auf geraeten mit-android-os/. Accessed: 2018-04-25.
- [2] Anzahl der Apps, die im Google Play Store heruntergeladen wurden. https://de.statista.com/ statistik/daten/studie/243412/umfrage/anzahl-vondownloads-im-google-play-store/. Accessed: 2018-04-25.
- [3] ART vs. Dalvik. http://www.areamobile.de/specials/26470-art-vs-dalvik-im-test-die-neue-android-runtime-im-vergleich. Accessed: 2018-05-28.
- [4] Steffen Bartsch u.a. "Zertifizierte Datensicherheit für Android-Anwendungen auf Basis statischer Programmanalysen." In: Sicherheit. 2014, S. 283–291.
- [5] Überdeckungsmaβe. http://home.edvsz.fhosnabrueck.de/skleuker/CSI/Methoden/ kombiquUeberdeckung.html. Accessed: 2018-05-29
- [6] *dynamische Analyse*. https://www.informatik.uni-bremen.de/st/lehre/re10/dynamische_analyse.pdf. Accessed: 2018-05-28.
- [7] Michael D Ernst. "Static and dynamic analysis: Synergy and duality". In: WODA 2003: ICSE Workshop on Dynamic Analysis. 2003, S. 24–27.
- [8] Marko Gargenta. Einführung in die Android-Entwicklung. O'Reilly Germany, 2011. URL: https: // books . google . de / books ? hl = de & lr = &id = 34S3Jt1ONTkC&oi=fnd&pg=PR5&dq=android+ architektur&ots=Hm7wBINdJG&sig=620owrYAI_ 6HXB7XDZjvfRM59KE#v=onepage&q&f=false.

- [9] Google Play Apps Statistik. https://de.statista.com/statistik/daten/studie/74368/umfrage/anzahl-der-verfuegbaren-apps-im-google-play-store/. Accessed: 2018-04-22.
- [10] Marcel Lehner und Eckehard Hermann. "Auffinden von verschleierter Malware". In: *Datenschutz und Datensicherheit DuD* 30.12 (2006), S. 768–772.
 ISSN: 1862-2607. DOI: 10.1007/s11623-006-0237-8. URL: https://doi.org/10.1007/s11623-006-0237-8.
- [11] Marktanteil von Android. https://www.netzwelt.de/news/164146 android vs ios plattform treue android 91 prozent deutlich hoeher.html. Accessed: 2018-04-25.
- [12] Request App Permissions. https://developer.android.com/training/permissions/requesting.html. Accessed: 2018-04-25.
- [13] RiskIQ report about Malicious Mobile Apps in Google Play. https://www.riskiq.com/press-release/riskiq-reports-malicious-mobile-apps-google-play-have-spiked-nearly-400/. Accessed: 2018-04-22.
- [14] Julian Scheid. "Sicherheit mobiler Geräte-Schutzmaßnahmen, Angriffsarten & Angriffserkennung auf Android". In: *Ausgewählte Themen der IT-Sicherheit* (2012), S. 7.
- [15] Sicherheitskonzepte von Linux. https://wiki.ubuntuusers.de/Archiv/Sicherheitskonzepte/. Accessed: 2018-04-25.
- [16] Philipp Trinius. *Visualisierung von Malware-Verhalten*. https://www1.cs.fau.de/filepool/publications/trinius_myphd_abstract.pdf. Accessed: 2018-05-29. 2010.
- [17] J. Yousefi, Y. Sedaghat und M. Rezaee. "Masking wrong-successor Control Flow Errors employing data redundancy". In: 2015 5th International Conference on Computer and Knowledge Engineering (ICCKE). 2015, S. 201–205. DOI: 10.1109/ICCKE. 2015.7365827.